

DOI:10.16652/j.issn.1004-373x.2025.07.013

引用格式:邓磊,云静,班琪.联合可信度学习的双向相关GCN网络谣言检测方法[J].现代电子技术,2025,48(7):85-94.

联合可信度学习的双向相关GCN网络谣言检测方法

邓磊^{1,2}, 云静^{1,2}, 班琪^{1,2}

(1. 内蒙古工业大学 数据科学与应用学院, 内蒙古 呼和浩特 010080;

2. 内蒙古自治区基于大数据的软件服务工程技术研究中心, 内蒙古 呼和浩特 010080)

摘要:针对目前谣言检测研究存在谣言传播言论与其标签关联性不足和传播结构特征丢失的问题,提出一种联合可信度学习的双向相关GCN网络谣言检测新方法。首先,根据谣言传播言论立场与其标签关系构建言论动机(善意或恶意)关系,训练可信度特征提取模型,以获取谣言言论可信度潜在表示;其次,融合嵌入表示和可信度潜在表示,分别对自上而下和自下而上传播方向节点进行相关性计算,随后使用Bi-GCN模型捕获双向传播特征;最后,将双向传播特征融合后输入到分类器中,以获取谣言检测分类结果。在微博数据集下进行实验,结果表明基于可信度学习方法优于基于立场检测方法,综合表现也超过先进的基线模型方法,尤其在谣言早期还未传播,就可达到91.1%的检测准确率。

关键词:谣言检测;可信度学习;动机关系;立场检测;Bi-GCN;相关性计算

中图分类号:TN711-34;TP181

文献标识码:A

文章编号:1004-373X(2025)07-0085-10

Joint credibility learning for rumor detection in bi-directional correlated GCN

DENG Lei^{1,2}, YUN Jing^{1,2}, BAN Qi^{1,2}

(1. College of Data Science and Application, Inner Mongolia University of Technology, Hohhot 010080, China;

2. Inner Mongolia Autonomous Region Engineering & Technology Research Center of Big Data Based Software Service, Hohhot 010080, China)

Abstract: In view of the insufficient correlation between rumor spreading statements and their labels and the loss of communication structure features in the current rumor detection research, a new method based on joint credibility learning for rumor detection in bi-directional correlated GCN (graph convolutional network) is proposed. Firstly, according to the relationship between the rumor spreading statement stances and their labels, which is constructed as the relationship of statement motivation (goodwill or badwill), a credibility feature extraction model is trained to obtain the potential representation of rumor statement credibility. Secondly, the embedding representation and credibility potential representation are fused, and the relevance is computed for the nodes of the top-down and bottom-up propagation directions, respectively, and then the bi-directional propagation features are captured by the Bi-GCN model. Finally, the bi-directional propagation features are fused and input into the classifier in order to obtain the results of rumor detection classification. The results of experiments conducted under the microblogging dataset show that the credibility-based learning approach outperforms the stance-based detection approach, and the comprehensive performance of the former also outperforms that of the advanced baseline modeling approach. In particular, an detection accuracy rate of 91.1% can be achieved at the early stage when the rumor has not yet spread.

Keywords: rumor detection; credibility learning; motivation relationship; stance detection; Bi-GCN; correlation computation

0 引言

随着在线社交媒体的快速发展,用户能够便捷地发布信息和获取信息。然而由于社交媒体对于用户发布的消息缺乏严格审核,并且用户在浏览信息时往往不会

投入太多精力对其真实性进行求证,因此为谣言的滋生和传播创造了有利条件。谣言,指的是在发布时未经证实的信息。例如新冠疫情期间的“用微波炉加热口罩可以消毒”以及“熏艾可以预防新冠肺炎”等。这些谣言不仅可能误导公众采取有害或无效的措施,还可能对人民的身体健康造成危害。因此,尽早发现并遏制谣言传播是至关重要的,因为这可以最大程度地减少不实言论的危害,对于维护社会稳定具有重大现实意义^[1]。

收稿日期:2024-07-20

修回日期:2024-08-12

基金项目:国家自然科学基金资助项目(62062055)

然而,谣言衍生迅速,数据庞大且内容繁杂,人工识别谣言虽能够保证一定的准确率,但不仅成本高昂,还效率低下。近年来,随着深度学习方法的快速发展,这种方法因其无需复杂的特征工程、能够自动从原始数据中提取高层次特征表示的特点,较传统的机器学习方法在谣言检测研究领域更受关注和使用。不过,基于深度学习的谣言检测方法仍面临两大主要挑战。

1) 如何有效地捕捉谣言传播言论与其标签之间的关联性,很多研究人员采用多任务方法,通过在原本文本语义中挖掘其他语义特征,如情感和立场信息,来捕获真假谣言的语义差异。例如文献[2]为谣言数据集引入情感标签和新颖性标签,利用BERT和GloVe提取前提和假设内容文本语义特征,将这些特征拼接后输入到以前神经网络组成的新颖性检测模型、情感检测模型和谣言检测模型,以最小化三个模型损失加权和为目标。文献[3]设计了一种将不规则谣言树构建为规则树的方法,利用树自注意力算法提取谣言传播路径每个节点及其分支的局部特征进行立场检测,通过使用提取到所有节点的立场特征进行树卷积和树池化操作,用于谣言检测。尽管这些方法丰富了语义表达,却未能将谣言言论与其标签建立深层次的对应关系,限制了谣言传播言论在谣言判断中的有效性。

2) 为了在传播过程中提取紧凑的结构特征,研究人员对谣言传播过程进行建模,提取事件本身的局部关系、全局关系以及与其他事件的关系等。然而,谣言传播路径往往不具备统一规律,因此很难用一种方法对所有谣言的传播路径进行建模。早期的建模方法,如RvNN^[4-5]、RNN^[6-7]和CNN^[8]方法,在捕获结构特征时存在深度和广度局限性。而GNN网络则通过图结构更有效地捕捉节点之间的复杂关系,成为主流的建模方法,其变体模型GCN和GAT也备受关注。然而,传统的GNN方法未能充分考虑到谣言传播路径中双向传播方向中节点间影响的异质性,无法自适应地关注不同邻居节点的信息。

基于上述挑战和缺点,本文提出联合可信度学习的双向相关GCN网络谣言检测方法,该模型包括可信度特征提取模块和节点相关性计算模块。为了进一步探究谣言传播言论与其标签的对应关系,本文将谣言传播言论与其标签的立场关系重新构建为动机关系(善意或恶意),采用多任务学习方法,使用重构的动机关系数据集对可信度学习网络进行预训练,并与谣言检测主任务进行联合训练和微调。为了增强节点更新的动态性,本文在双向传播过程中,于节点更新之前引入注意力机制算法,对源方向节点进行相关性计算,得出相关性系数;

对源方向节点特征表示进行加权求和,从而更新GCN网络中节点表示,以更有效地捕获谣言传播的结构特征。

综上所述,本文的主要贡献包括以下三个方面。

1) 提出可信度学习子任务,将传统的立场关系重构为动机关系,并建立多任务学习模型,结果表明可信度学习子任务的性能高于立场检测。

2) 提出一种方法来计算谣言双向传播节点间的相关性,节点融合直接传播源邻居节点的特征更具相关性,更有效提升对谣言传播特征的捕获能力。

3) 在真实微博数据集中,实验结果表明,本文所提方法综合性能优于最先进的基线,并且在谣言早期传播阶段,检测准确率可达91.1%。

1 相关工作

1.1 基于多任务学习的谣言检测

多任务学习的目的是利用不同任务之间的相关性,通过联合训练来改善各个任务的泛化能力和准确性。多任务学习应用广泛,在谣言检测领域主要体现在联合立场检测和联合情感分析任务中。

情感分析任务是通过分析帖子内容中的情感表达来识别用户的情感状态,如讨厌、害怕、伤心等。研究表明,虚假谣言通常具有煽动性和误导性,更易引发更强烈的情感反应,特别是消极情感^[9]。文献[10]将帖子声明和评论的语义特征与情感特征拼接后,分别输入谣言检测分类器和情感检测分类器,通过加权求和二者损失作为共同损失,以优化模型参数。类似地,文献[11]采用词嵌入方法将帖子声明转换为嵌入向量,分别进行情感检测和谣言检测,并最小化二者损失来优化模型参数。文献[12]在情感检测的基础上,增加了新颖性检测,并对两者进行数据适应性的预训练,使用GloVe提取新颖性特征,BERT提取情感特征,融合它们用于谣言检测。

立场检测任务定义为辨别帖子内容对目标谣言的态度,即支持、否定或中立。据研究,谣言传播期间,虚假谣言往往比真实谣言更容易受到否定或质疑,导致其立场分布方面存在显著差异^[13]。文献[14]利用GRU网络构建元网络和多个任务网络,元网络收集所有任务共享的高层元知识,谣言检测和立场检测执行时需要结合各自的语义和元知识特征,缓解了多任务间的语义差异。文献[15]分别研究了自下而上和自上而下的传播方向使用RvNN的效果。首先使用RvNN对传播节点进行立场检测以获取立场特征;然后运算传播节点与帖子声明的语义特征得到每个节点的注意力分数;最后通过加权求和立场特征用于谣言检测,结果表明自上而下的性

能要更好。文献[16]构建了一个基于单词和帖子异构图的模型,通过自适应图注意力层来捕获邻居特征更新节点进行立场检测,随后再经过图池化层和自适应图注意力层进行谣言检测,将二者损失累加以实现联合训练。

在以上描述的谣言检测子任务中,虽然其综合性能优于单一任务,但情感分析和立场检测任务并未深入探索谣言立场与真假标签的关联性,导致与谣言检测任务的关联性不足。在这一背景下,对传统的立场检测任务进行改进,引入了可信度学习的概念。通过区分帖子和评论的善意与恶意见来判断其可信度,基于这个思路,可以认为善意的帖子很可能是真实的,而恶意的帖子则很可能是虚假的。因此,模型在解决谣言检测这个二分类问题上具有积极的作用。

1.2 基于传播结构的谣言检测

谣言在传播过程中具有“自我纠正”的特性,用户分享对谣言的看法也可以作为谣言检测的重要依据^[17]。考虑到谣言传播路径的复杂性,很难用统一的方法去提取不同谣言的层次特征。图神经网络(GNN)能够在不规则和非结构化的图数据中提取和挖掘特征,所以成为了建模谣言传播结构的主流方法^[18]。而GCN和GAT作为GNN的变体,同样广泛应用于谣言检测任务中。

文献[19]提出两种根据谣言传播的时间和顺序生成快照的方式,并利用双向GCN网络更新每个快照包含的节点特征,以捕获谣言传播的动态性特征。文献[20]提出多跳GAT网络,使节点更新能够融合更远视野域的全局特征,并引入差分时间感知网络以捕获谣言传播的时间特征。文献[21]使用GNN网络更新节点特征以捕获传播特征,同时使用CNN网络获取谣言的语义特征,并通过对比学习分析这两种特征的关系以约束模型的学习。文献[22]提出基于GNN的双层特征聚合方法,从文本内容和谣言传播结构中学习单词和文本粒度的高级表示来进行谣言检测。文献[23]通过GCN网络建模用户与谣言声明以及谣言声明与其评论之间的关系,拼接这两种关系后用于谣言检测。

以上方法说明了基于邻居节点重要性进行节点更新的重要性,以及结合两个传播方向的结构特征的重要性。然而,据了解并没有相关方案能同时联合这二者的优点来改进谣言检测任务。本文方法受双向GCN和GAT方法的启发,使用注意力机制算法来计算相关性,在每个传播方向节点更新时,依据相关性将直接传播源节点的特征加权融合,以提高模型对传播结构特征的捕获能力。

2 联合可信度学习的双向相关GCN网络

2.1 问题描述

定义1:谣言事件。 $r = \{r_1, r_2, \dots, r_m\}$ 是一组用于谣言检测的所有事件实例,其中 r_i 是第 i 个事件, m 是事件数量。 r_i 由帖子声明及其评论组成,表示为 $r_i = \{p_{i,0}, p_{i,1}, \dots, p_{i,n}\}$, n 是 r_i 评论的个数, $p_{i,j}$ 是谣言 r_i 的第 j 个评论,其中 $p_{i,0}$ 表示第 i 个事件的声明。

定义2:可信度检测函数。谣言传播结构中,每个评论内容对于根帖子(谣言声明)有着不同的态度,支持、否定或中立。

如图1所示,当谣言标签为真时,其支持的言论设定为善意,否定的言论设定为恶意;同样,当谣言标签为假时,其支持的言论设定为恶意,否定的言论设定为善意。给定一个谣言 r_i ,判断其所有交互 $p_{i,j}$ 的交互类型,即 $f_{cd}: p_{i,j} \rightarrow y_{i,j}^{cd}$,其中 $y_{i,j}^{cd} \in \{\text{善意}, \text{恶意}\}$ 。

定义3:谣言检测函数。通过对传播树建模,给定一个谣言 r_i ,结合谣言传播树中的帖子和评论,判断 r_i 的标签,即 $f_m: r_i \rightarrow y_i^{rd}$,其中 $y_i^{rd} \in \{\text{非谣言}, \text{假谣言}\}$ 。

2.2 模型概述

本文提出了联合可信度学习的双向相关GCN网络谣言检测方法(CDR-aBiGCN),框架如图2所示,主要由以下三个组件组成。

1) 可信度特征提取网络模块。负责提取参与谣言传播的言论与标签之间的可信度特征关系。

2) 双向相关GCN网络模块。负责聚合谣言文本嵌入和可信度特征,并构建自上而下和自下而上传播图。该模块通过计算双向节点间的相关性,利用GCN网络更新节点特征,获取谣言传播结构特征。

3) 判别输出模块。将所有谣言传播过程中的节点表示融合为一个整体表达,送入线性分类层,用于生成谣言的分类结果,同时计算损失函数数值实现更新双向相关GCN网络和微调可信度特征提取网络。

2.3 传播关系构建

通过对谣言传播关系建模,可以学习到其结构特征。以往的研究已经证明同时利用双向特征作为互相补充,可以提升模型的性能。

同样,本文也选择使用两个传播方向。在事件 r_i 中涵盖多个节点 $p_{i,0}, p_{i,1}, \dots$,使用图(Graph)的数据结构构建关系。

1) 自上而下(Top-Down, TD)的传播图,从根节点到叶子节点路径方向中,所有节点的连接关系能够有效地捕获节点传播的特点,反映事件传播的自然序列,展示节点之间的层次结构和因果关系。




图1 谣言传播示例图




图2 CDR-aBiGCN网络模型框架图

2) 自下而上(Bottom-Up, BU)的传播图,从叶子节点到根节点路径方向中,所有节点的连接关系可以揭示帖子的自我纠正特征,凸显信息的反馈机制,强调了事件最终状态对整个传播过程的关键影响。

自上而下的传播图 $G^{\text{TD}} = \langle V, E \rangle$, 其中 V 是节点信息, E 表示节点的传播方向(根节点 $\rightarrow$ 叶子节点)。 $V = r_i = \{p_{i,0}, p_{i,1}, \dots, p_{i,n}\}$, 包含事件中所有节点信息。同理, 可得出自下而上传播图 G^{BU} 。

2.4 可信度特征提取网络模块

以往的研究人员使用多任务学习方法来增强语义表达能力。在此基础上,本文提出了一个新的子任务,

即可信度学习,通过将谣言传播言论与其标签建立联系,以提取利于谣言判断的可信度特征。文本嵌入采用基于Transformer的双向编码器BERT^[24],以捕获丰富的语义特征,此前,BERT已被广泛应用于翻译和摘要等任务中,显示出强大的文本理解能力。给定一个帖子内容 $p_{i,j}$, 对其分词并按顺序建模得列表 $p_{i,j} = \{w_1, w_2, \dots, w_o\}$, o 为单词总数,随后使用BERT获取特征嵌入。

$$h'_{i,j} = \text{BERT}(p_{i,j}) = \text{BERT}(\{w_1, w_2, \dots, w_o\}) \quad (1)$$

式中, $h'_{i,j} \in \mathbf{R}^d$ 是BERT预训练模型中最后一层CLS的隐藏状态, d_w 是文本嵌入的维度。

然后,将文本嵌入 h_{ij}^t 作为模型原始输入 $h_{ij}^{d_0}$,进行一系列的线性变换和非线性激活函数,得到了逐层变换的可信度特征表示:

$$h_{ij}^{d_1} = \sigma(W_1 h_{ij}^{d_0} + b_1) \quad (2)$$

$$h_{ij}^{d_2} = \sigma(W_2 h_{ij}^{d_1} + b_2) \quad (3)$$

式中: σ 为激活函数; W_1 、 W_2 分别是线性变化操作第一层和第二层的权重矩阵; b_1 、 b_2 分别是线性变化操作第一层和第二层的偏置向量。这一系列变换实现了对文本嵌入的逐层特征提取,通过非线性映射和权重调整,逐步形成了更抽象的表示 $h_{ij}^{d_2}$ 。

最后,获取 $h_{ij}^{d_2}$ 的可信度标签概率,应用Softmax函数将可信度特征转换为类别概率。具体而言,使用以下公式计算概率分布。

$$\hat{Y}_{ij}^{ed} = \text{Softmax}(W_3 h_{ij}^{d_2} + b_3) \quad (4)$$

式中: $\hat{Y}_{ij}^{ed} \in \{\text{善意}, \text{恶意}\}$ 是可信度的预测概率; W_3 和 b_3 是全连接层的权重和偏置。

2.5 双向相关GCN网络模块

GCN网络能够自适应地学习图结构中节点的特征和关系,因此可以有效地对不同长度和形状的谣言传播网络进行建模。然而,传统的双向GCN网络的节点更新方法存在不足,无法根据节点与不同邻居节点的相关性获得不同的更新,导致动态性缺乏。本文使用双向相关GCN网络,节点更新之前先进行相关性计算,随后使用GCN网络捕获结构特征,从而使得节点间的结构更加紧凑。在可信度特征提取模块中,得到了可信度特征嵌入 h_{ij}^d ,通过concat函数拼接原始文本嵌入 h_{ij}^t ,可得特征增强后的节点特征:

$$h_{ij} = \text{concat}(h_{ij}^d, h_{ij}^t) \quad (5)$$

谣言传播的结构特征捕获通常使用节点更新方法,具体而言:计算自身节点和其他节点的相关性,将其他节点的特征根据相关性添加到自身节点表示中。

节点之间的相关性通过注意力算法进行计算,逐个评估节点 j 与其直接传播源节点 v 的相关性。

$$e_{i,j,v} = a\left(\left[Wh_{i,j} \parallel Wh_{i,v}\right]\right) \quad (6)$$

$$a_{i,j,v} = \text{Softmax}(e_{i,j,v}) \quad (7)$$

式中: $v \in N_j$, N_j 是 j 的直接传播源的相邻节点集合; $[\cdot, \cdot]$ 是拼接操作; a 和 W 是线性变化权重参数;Softmax是归一化函数。

然后获取相邻节点的特征,更新节点特征表示为:

$$h_{ij} = \sigma\left(\sum_{v \in N_j} a_{i,j,v} Wh_{i,v}\right) \quad (8)$$

在自上而下的传播结构中,重复式(6)~式(8),可以融合更远视野域节点特征,融合两跳结构信息的节点 j 的计算公式为:

$$h_{i,j}^{TD} = h_{i,j}^{(1)} = \sigma\left(\sum_{v \in N_{i,j}} a_{i,j,v} Wh_{i,v}\right) \quad (9)$$

$$h_{i,j}^{TD} = h_{i,j}^{(2)} = \sigma\left(\sum_{v \in N_{i,j}} a_{i,j,v} Wh_{i,v}^{(1)}\right) \quad (10)$$

式中: $h_i^{TD} = \{h_{i,0}^{TD}, h_{i,1}^{TD}, \dots, h_{i,n}^{TD}\}$, $h_i^{TD} \in \mathbf{R}^{n \times 64}$ 表示谣言 i 的整个传播过程所有传播节点; $h_{i,j}^{TD} \in \mathbf{R}^{64}$ 表示谣言 i 的传播节点 j 的特征表示,同理,可计算得到自下而上传播过程的表示 h_i^{BU} 。为了获取整体传播结构特征,将两个传播方向的节点按照式(11)进行融合。

$$H_i^* = \text{mean}(h_i^*) = \text{mean}\left(\{h_{i,0}^*, h_{i,1}^*, \dots, h_{i,n}^*\}\right) \quad (11)$$

式中: $H_i^* \in \mathbf{R}^{1 \times 64}$ 表示传播方向为“*”的传播结构特征;“*” $\in \{TD, BU\}$;mean为平均函数。

2.6 分类输出

给定谣言 r_i ,经过BERT嵌入后得到其表示为 h_i^c 。随后,将该表示向量与可信度检测模块的输出 h_i^c 进行拼接,分别通过不同的传播结构更新后得到 h_i^{TD} 和 h_i^{BU} 。接着,使用平均函数(mean)分别对这两个向量求平均得到 H_i^{TD} 和 H_i^{BU} 。最后,通过合并函数(concat)拼接后输入到线性分类层,谣言分类概率表述为:

$$\hat{Y}_i^{rd} = \text{Softmax}\left(W_4(\text{concat}(H_i^{TD}, H_i^{BU})) + b_4\right) \quad (12)$$

式中: $\hat{Y}_i^{rd} \in \{\text{非谣言}, \text{假谣言}\}$ 为谣言 i 是谣言与否的预测概率; W_4 和 b_4 是全连接层的权重和偏置。

3 实验

3.1 数据集

本文在可信度学习子任务中,采用SemEval-2019的task7英文立场数据集,通过百度翻译接口将其翻译为中文,以构建中文动机数据集,该立场数据集来源于真实的社交网络——Twitter和Reddit,具体数据分布情况如表1和表2所示。

表1 可信度检测立场数据统计

数据集	支持	否定	总计
训练集	910	344	1 254
	15	34	49
验证集	94	71	165
	8	11	19
测试集	141	92	233
	16	9	25

表2 可信度检测谣言标签数据统计

数据集	非谣言	假谣言	总计
训练集	137	62	223
	7	17	
验证集	8	12	29
	2	7	
测试集	22	30	71
	9	10	

而在谣言检测的主任务中,使用 Weibo16 数据集,这是当前谣言检测研究中使用最广泛的中文数据集之一,其数据来自于中国的微博平台,数据分布情况如表3所示。

表3 谣言检测 Weibo16数据集数据分布

统计	数量
源帖子数	4 664
非谣言(NR)	2 351
假谣言(FR)	2 313
用户数	2 746 818
传播帖子数	3 805 656

3.2 对比实验

为了进一步验证本文所提出的谣言检测方法的有效性,与以下13种研究方法进行对照实验。

- 1) DTC^[25],基于决策树分类器提取和分析信息传播的帖子特征。
- 2) RFC^[26],基于随机森林分类器,利用用户、内容和结构属性作为手工特征。
- 3) SVM-TS^[27],基于线性SVM分类器,利用手工制作的社交上下文特征,使用时间序列对特征值随时间的变化进行建模。
- 4) SVM-RBF^[28],基于SVM的RBF内核模型,与DTC类似,使用谣言帖子的手工特征。
- 5) SVM-TK^[29],基于树核的SVM分类器,通过核学习方法捕获传播结构特征。
- 6) SVM-HK^[30],使用混合核的SVM分类器,通过核学习方法捕获传播结构特征。
- 7) RvNN^[17],将帖子及其评论建模为对话树,并采用递归神经网络学习传播特征。
- 8) TD-RvNN-GA^[4],在之前的研究上^[17],将每一个传播过程中的言论通过注意力机制赋予权重。
- 9) Bi-GCN^[31],建模谣言传播言论,使用双向图卷积网络捕获双向(自上而下和自下而上)结构特征。

10) GLAN^[32],使用CNN网络力机制融合帖子间的语义潜在表示,而后将帖子、转发和用户关系建模为全局关系异构图,捕获结构特征。

11) HAGNN^[22],设置GCN来捕获结构特征,再设置门控GNN来更新文本和单词的聚合表示,池化后经Softmax函数输出分类结果。

12) SBAG^[33],首先预训练多层感知网络捕获社交机器人特征,然后嵌入特征构建多个GNN网络对帖子建模。

13) SDR-aBiGCN,将本文的可信度检测子任务替换为立场检测子任务,在谣言检测网络训练时,建模融合谣言传播言论的态度立场潜在特征,随后使用双向相关GCN网络训练。

3.3 实验设置

在实验环节,采用BERT预训练模型进行文本嵌入表示,其维度设定为默认的768维。在可信度学习子任务中,使用Adam优化器,批尺寸大小为64,学习率为0.001,训练轮次为100,Dropout率为0.5。为了确保训练的有效性,引入早停机制。具体而言,如果验证集损失在10个epoch后仍未减少,将认为模型已经收敛,便会停止训练并保存模型权重,以备用于后续处理检测模块输入数据。

在谣言检测主任务中,同样采用了Adam优化器,训练轮次为100,学习率为0.000 1,批尺寸大小为64。为了更好地捕捉谣言传播特征,构建有向图数据结构,并设置GCN卷积层数为2。

3.4 实验表现

实验结果如表4所示,本文提出的联合可信度学习的多任务方法优于其他多任务学习基线方法0.004~0.01,优于单谣言检测方法0.006~0.035,优于基于传统手工特征方法0.065~0.149。

在第一组实验中,明显可见基于传统手工特征提取的方法效果明显低于基于深度学习方法的效果。具体而言,前四类方法(DTC、RFC、SVM-TS和SVM)的性能较低,这可能是由于手工特征的质量受到限制,而这些特征可能并不适合直接用于模型判断,从而导致准确率较低。相比之下,SVM-HK和SVM-TK通过核方法捕获结构特征,显示出了更好的性能,也表明了传播结构特征对于谣言判断是有益的特征。

在第二组实验中,探索了不同传播结构特征捕获能力的差异。TD-RvNN和TD-RvNN-GA对比得知,加入注意力机制可以选择有效的内容数据进行谣言判断。Bi-GCN方法要比RvNN方法优0.013左右,其原因是RvNN方法是一种深度遍历方法,对于捕获广度结构特征能力

不足。GLAN虽然可以捕获到更远距离的节点结构特征,但是CNN网络局部特征提取有限,容易造成对复杂传播结构特征捕获不足。HAGNN和Bi-GCN在第二组实验中表现最好,证明了GNN类模型在捕获传播结构特征方面的能力,也进一步验证了使用双向传播特征(Bi-GCN)优于单向传播(HAGNN)的性能。

表4 对比实验结果

组别	方法	准确率	非谣言(NR)			假谣言(FR)		
			精确率	召回率	F_1 分数	精确率	召回率	F_1 分数
第一组	DTC	0.831	0.815	0.847	0.83	0.847	0.815	0.831
	RFC	0.849	0.947	0.739	0.83	0.786	0.959	0.864
	SVM-TS	0.857	0.878	0.83	0.857	0.839	0.885	0.861
	SVM-RBF	0.818	0.815	0.824	0.819	0.822	0.812	0.817
	SVM-HK	0.88	0.911	0.861	0.885	0.866	0.93	0.896
	SVM-TK	0.902	0.963	0.836	0.895	0.855	0.968	0.908
第二组	TD-RvNN	0.932	0.932	0.912	0.921	0.921	0.961	0.941
	TD-RvNN-GA	0.948	0.952	0.944	0.948	0.944	0.952	0.948
	Bi-GCN	0.961	0.962	0.962	0.96	0.961	0.964	0.961
	GLAN	0.946	0.949	0.943	0.946	0.943	0.948	0.945
	HAGNN	0.957	0.970	0.917	0.943	0.949	0.983	0.966
第三组	SBGA	0.957	0.967	0.947	0.957	0.947	0.967	0.957
	SDR-aBiGCN	0.963	0.953	0.969	0.961	0.972	0.954	0.964
	CDR-aBiGCN	0.967	0.956	0.980	0.966	0.981	0.955	0.967

在第三组实验中,相比于一般的传播结构上的研究方法,通过增加辅助任务(SBGA、SDR-aBiGCN)可以明显提高检测性能。SBGA的假谣言检测性能要优于SDR-aBiGCN和本文提出的CDR-aBiGCN,证明了用户特征对于谣言判别的有效性,但其非谣言的检测能力不足,原因可能为用户信息并不真实,进而无法准确判断是否是机器人,用户特征不明显,将真人识别为机器人。CDR-aBiGCN和SDR-aBiGCN的实验结果显示,基于可信度学习的子任务方法要比基于立场检测的子任务在谣言检测方面具有更佳的检测性能。

本文提出的谣言检测方法,相比以上提到的基线模型,在非谣言的精确率和假谣言的召回率方面表现略低,但在其他指标上均取得了最好的表现。因此,本文提出的方法具有较高的检测性能。

3.5 消融实验

本文提出的CDR-aBiGCN模型主要由可信度学习网络、相关性计算和BiGCN网络三部分组成。为了评估本文方法中各个组件的有效性,设计以下几个变异模型,并将其性能与相关方法进行比较。

w/o CD:删除可信度学习模块,取消可信度特征嵌入,使用文本初始嵌入用于分类。

w/o A:去除双向相关性计算方法,节点更新方式采用传统GCN网络更新方法。

w/o BU:删除自下而上的谣言传播特征,只使用自上而下传播特征。

w/o TD:删除自上而下的谣言传播特征,只使用自下而上传播特征。

如表5所示,可以观察到每个组件对整个模型都是不可或缺的。由传播结构的变异模型中可见,捕获的传播特征网络方法的性能表现为:Bi-GCN>BU-GCN>TD-GCN。在去除TD后,性能下降并不明显,这表明自上而下捕获的传播特征对整体模型判断的贡献度相对较小。然而,当去除BU后,模型性能下降明显,表明了来自于子节点的自下而上表示的重要性,证明了谣言在传播过程中具有自我纠正的特点,可以作为谣言判断的重要依据特征。综合考虑二者的结合对优化模型性能具有显著作用。

在相同条件下的变异模型中,当去除可信度特征提取模块后,模型的准确率下降幅度为0.01~0.025。表明可信度特征增强了语义表示,在谣言检测任务中,起到了重要的作用。当去除双向相关性计算权重方法后,模型性能下降,证明了在GCN网络中传统的节点更新方法的节点间更新相关性不足,从而导致传播特征的缺失。

综上所述,本文提出的模型的各个组件对于整个模型都具有关键作用,证明了该框架的有效性。

表5 消融实验结果

方法	w/o CD	w/o A	w/o BU	w/o TD	准确率
1	√				0.957
2		√			0.962
3	√	√			0.955
4	√		√		0.930
5	√			√	0.941
6		√	√		0.939
7		√		√	0.959
8	√	√	√		0.924
9	√	√		√	0.938
10			√		0.955
11				√	0.960
12(Ours)					0.967

3.6 早期检测表现

如果能够尽早识别判断谣言,就可以尽可能地降低对社会的危害,为此很多研究开始了对早期谣言检测。对于这项工作,本文采用两种类型:一种是根据帖子声明发布后经过的时间;另一种是根据传播树深度的不同数据比例设置,来验证模型是否能够根据当前早期时刻携带的有限信息正确识别谣言。实验结果如图3所示。





图3 早期检测模型表现

可以观察到,在谣言传播的早期阶段,由于交互数据较少,所有方法的性能都显著降低,唯有本文提出的方法表现出相对较高的性能,在只有0.1%数据下准确率可达91.1%。随着评论数据的逐渐增多,检测的准确率也在不断提高,这进一步证明了谣言传播具有“自我纠正”的特点。与传统的立场检测子任务方法相比,本文方法能够在早期获取谣言声明的可信度特征,分析言论动机是否出于善意或恶意,从而为谣言判断提供了有效支持。

3.7 特征可视化

图4展示了模型训练过程中的标签可视化。其中:0表示非谣言;1表示假谣言。




图4 特征可视化图

图4a)展示了仅使用文本嵌入的情况,不同类别的谣言表示存在较高的重合度,表明仅靠文本嵌入无法有效区分谣言与真实信息。

图4b)展示了帖子声明经可信度特征提取后的分类结果,显著增强不同类别间的区分差异,这进一步证明了在谣言检测中利用可信度特征的有效性。

图4c)展示了真实标签样本的分布情况,为模型分类提供了参考。

图4d)展示了本文方法的预测结果,此方法结合可信度特征和双向相关GCN网络,使不同类别之间的特征区别更加显著,进一步提高了模型对真假谣言的区分能力。

4 结 语

本文提出一种联合可信度学习的双向相关GCN网络谣言检测方法,该模型采用可信度检测作为子任务进行多任务学习,在真实世界的微博数据集进行训练和测

试,主要结论有:

1) 基于可信度学习的子任务方法相较于基于立场检测子任务方法,建立了谣言传播言论与其标签的深层次对应关系,谣言检测性能表现更优秀;

2) 谣言传播网络节点更新方式采用双向相关性计算,能够更好地捕捉节点在双向传播过程中的异质性特征,从而有助于提取出更为紧凑的结构特征。

本文在捕获结构特征时,特征更新局限于网络的两跳范围,无法捕获较远距离的节点特征。因此,下一步研究的重点将集中在扩展结构特征融合的范围,以捕获更远距离的节点特征,从而进一步提升谣言检测的性能。

注:本文通讯作者为云静。

参 考 文 献

- [1] 孟凡森,魏霞,黄德启,等.基于ACON-Transformer的谣言检测研究[J].现代电子技术,2022,45(21):67-76.
- [2] KUMARI R, ASHOK N, GHOSAL T, et al. Misinformation detection using multitask learning with mutual learning for novelty detection and emotion recognition [J]. Information processing & management, 2021, 58(5): 102631.
- [3] BAI N, MENG F R, RUI X B, et al. A multi-task attention tree neural net for stance classification and rumor veracity detection [J]. Applied intelligence, 2023, 53(9): 10715-10725.
- [4] MA J, GAO W, JOTY S R, et al. An attention-based rumor detection model with tree-structured recursive neural networks [J]. ACM transactions on intelligent systems and technology, 2020, 11(4): 1-28.
- [5] HUANG Q, ZHOU C, WU J, et al. Deep structure learning for rumor detection on twitter [C]// 2019 International Joint Conference on Neural Networks (IJCNN). New York: IEEE, 2019: 1-8.
- [6] LIU Y, WU Y F B. Early detection of fake news on social media through propagation path classification with recurrent and convolutional networks [C]// Proceedings of the AAAI Conference on Artificial Intelligence. [S.l.]: AAAI, 2018: 354-361.
- [7] CHEN T, LI X, YIN H Z, et al. Call attention to rumors: Deep attention based recurrent neural networks for early rumor detection [C]// Trends and Applications in Knowledge Discovery and Data Mining. Heidelberg: Springer, 2018: 40-52.
- [8] YU F, LIU Q, WU S, et al. A convolutional approach for misinformation identification [EB/OL]. [2022-03-21]. <https://doi.org/10.24963/ijcai.2017/545>.
- [9] GHANEM B, ROSSO P, RANGEL F. An emotional analysis of false information in social media and news articles [J]. ACM transactions on internet technology (TOIT), 2020, 20(2): 1-18.
- [10] 马儀,邵玉斌,杜庆治,等.基于联合情感的多任务谣言检测方法[J].云南大学学报(自然科学版),2024,46(4):642-653.
- [11] CHOUDHRY A, KHATRI I, JAIN M, et al. An emotion-aware multitask approach to fake news and rumor detection using transfer learning [J]. IEEE transactions on computational social systems, 2022, 11(1): 588-599.
- [12] KUMARI R, ASHOK N, GHOSAL T, et al. What the fake? Probing misinformation detection standing on the shoulder of novelty and emotion [J]. Information processing & management, 2022, 59(1): 102740.
- [13] MENDOZA M, POBLETE B, CASTILLO C. Twitter under crisis: Can we trust what we RT? [C]// Proceedings of the First Workshop on Social Media Analytics. New York: ACM, 2010: 71-79.
- [14] ZHANG H W, QIAN S S, FANG Q, et al. Multi-modal meta multi-task learning for social media rumor detection [J]. IEEE transactions on multimedia, 2022, 24: 1449-1459.
- [15] YANG R C, MA J, LIN H Z, et al. A weakly supervised propagation model for rumor verification and stance detection with multiple instance learning [C]// Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2022: 1761-1772.
- [16] LI C, PENG H, LI J X, et al. Joint stance and rumor detection in hierarchical heterogeneous graph [J]. IEEE transactions on neural networks and learning systems, 2022, 33(6): 2530-2542.
- [17] MA J, GAO W, WONG K F. Rumor detection on twitter with tree-structured recursive neural networks [C]// Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics. [S.l.]: ACL, 2018: 1980-1989.
- [18] YAN Y Q, WANG Y J, ZHENG P. Rumor detection on social networks focusing on endogenous psychological motivation [J]. Neurocomputing, 2023, 552: 126548.
- [19] CHOI J, KO T, CHOI Y, et al. Dynamic graph convolutional networks with attention mechanism for rumor detection on social media [J]. Plos one, 2021, 16(8): e0256039.
- [20] CHEN J H, ZHANG W Y, MA H C, et al. Rumor detection in social media based on multi-hop graphs and differential time series [J]. Mathematics, 2023, 11(16): 3461.
- [21] GAO Y, WANG X, HE X N, et al. Rumor detection with self-supervised learning on texts and social graph [J]. Frontiers of computer science, 2023, 17(4): 174611.
- [22] XU S Z, LIU X D, MA K, et al. Rumor detection on social media using hierarchically aggregated feature via graph neural networks [J]. Applied intelligence, 2023, 53(3): 11-14.
- [23] LIU T R, CAI Q, XU C X, et al. Rumor detection with a novel graph neural network approach [EB/OL]. [2024-04-09]. <https://doi.org/10.48550/arXiv.2403.16206>.
- [24] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding [EB/OL]. [2022-09-26]. <https://doi.org/10.18653/v1/n19-1423>.

- [25] CASTILLO C, MENDOZA M, POBLETE B. Information credibility on twitter [C]// Proceedings of the 20th International Conference on World Wide Web. New York: ACM, 2011: 675-684.
- [26] KWON S, CHA M, JUNG K. Rumor detection over varying time windows [J]. PloS one, 2017, 12(1): e0168344.
- [27] MA J, GAO W, WEI Z Y, et al. Detect rumors using time series of social context information on microblogging websites [C]// Proceedings of the 24th ACM International on Conference on Information and Knowledge Management. [S. l.: s. n.], 2015: 1751-1754.
- [28] YANG F, LIU Y, YU X H, et al. Automatic detection of rumor on Sina Weibo [C]// Proceedings of the ACM SIGKDD Workshop on Mining Data Semantics. [S. l.: s. n.], 2012: 1-7.
- [29] MA J, GAO W, WONG K F. Detect rumors in microblog posts using propagation structure via kernel learning [C]// Conference of the European Chapter of the Association for Computational Linguistics. [S. l.: s. n.], 2017: 708-717.
- [30] WU K, YANG S, ZHU K Q. False rumors detection on Sina Weibo by propagation structures [C]// 2015 IEEE 31st International Conference on Data Engineering. New York: IEEE, 2015: 651-662.
- [31] BIAN T, XIAO X, XU T Y, et al. Rumor detection on social media with bi-directional graph convolutional networks [J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(1): 549-556.
- [32] YUAN C Y, MA Q W, ZHOU W, et al. Jointly embedding the local and global relations of heterogeneous graph for rumor detection [C]// 2019 IEEE International Conference on Data Mining (ICDM). New York: IEEE, 2019: 796-805.
- [33] HUANG Z, LÜ Z L, HAN X Y, et al. Social bot-aware graph neural network for early rumor detection [C]// Proceedings of the 29th International Conference on Computational Linguistics. [S. l.: ICCL, 2022: 6680-6690.
- [34] 赵东波, 李辉. 一种改进的FCM遥感图像变化检测方法[J]. 电子设计工程, 2023, 31(9): 156-160.

作者简介: 邓 磊(1999—), 男, 内蒙古兴和人, 硕士研究生, 主要研究方向为自然语言处理、谣言检测。

云 静(1980—), 女, 内蒙古呼和浩特人, 副教授, 硕士生导师, 主要研究方向为图像处理、自然语言处理、机器学习。

班 琪(1999—), 女, 内蒙古锡林郭勒人, 硕士研究生, 主要研究方向为自然语言处理、跨语言摘要生成。